CentraleSupélec
Mention Sciences des Données et de l'Information

3MD3090 – IA et Environnement
Responsable : Gilles Faÿ

Municipal Solid Waste Forecasting

Reproduction partielle et extensions de Mudannayake et al. (2022)

Côme Genet

Avril 2026

CentraleSupélec

Table des matières

1 Introduction **2**

2 Données **2**

2.1 Description du dataset 2

2.2 Exploration 3

2.3 Prétraitement 4

3 Modèles **4**

3.1 Modèles reproduits du papier 4

3.2 Foundation model : Chronos 4

3.3 Approche multi-model 5

3.4 Chronos multi-model 5

4 Résultats **5**

4.1 Comparaison avec le papier 5

4.2 Chronos : impact de l'horizon 6

4.3 Approche multi-model 7

4.4 Chronos multi-model 7

5 Empreinte carbone **7**

5.1 Méthodologie 7

5.2 Résultats 8

6 Discussion et critiques du papier **8**

7 Conclusion **9**

1 Introduction

La gestion des déchets municipaux (Municipal Solid Waste, MSW) représente un enjeu environnemental et logistique majeur dans les villes modernes. La capacité à prédire avec précision les volumes quotidiens de déchets permettrait aux autorités d'optimiser les ressources de collecte, réduisant ainsi les coûts opérationnels et l'empreinte carbone associée.

Ce projet s'inscrit dans le cadre du cours *IA et Environnement* à CentraleSupélec et reproduit partiellement les travaux de Mudannayake et al. [2022] sur la prédiction des déchets municipaux par des approches de machine learning et deep learning. Il propose ensuite trois extensions originales :

- Le test d'un foundation model de forecasting (Chronos, Amazon 2024) en stratégie zero-shot et rolling forecast ;
- La reproduction de l'approche multi-model proposée dans l'article ;
- Une mesure de l'empreinte carbone de chaque modèle, dimension absente du papier original.

L'ensemble du code est disponible sur GitHub : `https://github.com/comegenet/msw-forecasting`.

2 Données

2.1 Description du dataset

Le dataset utilisé est le *Waste Collection & Diversion Report (daily)* de la ville d'Austin, Texas, disponible publiquement via le portail open data de la ville [City of Austin, 2024]. Il contient 740 873 entrées individuelles de collecte, couvrant la période 2003–2021. Chaque ligne correspond à une collecte unique et inclut la date, le type de déchet, le site de dépôt et le poids collecté (en livres).

Conformément à la méthodologie du papier, nous agrégeons les poids par jour sur la période 2005–2019, aboutissant à une série temporelle de 5 005 observations journalières.

2.2 Exploration

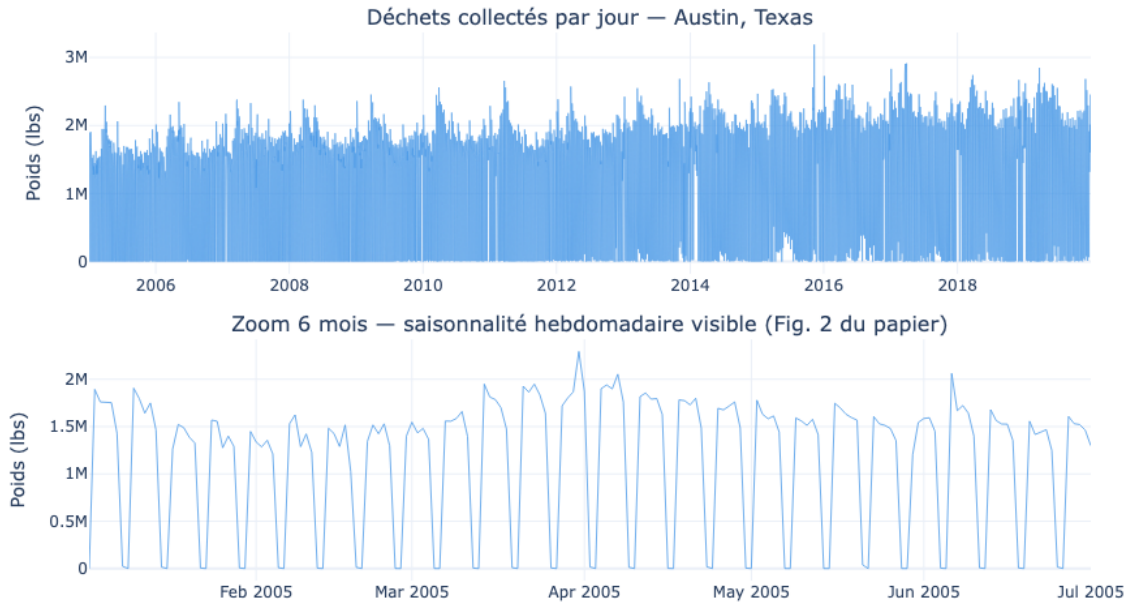

FIGURE 1 – Série temporelle des déchets collectés par jour à Austin (2005–2019). Les creux brutaux correspondent aux weekends et jours fériés sans collecte.

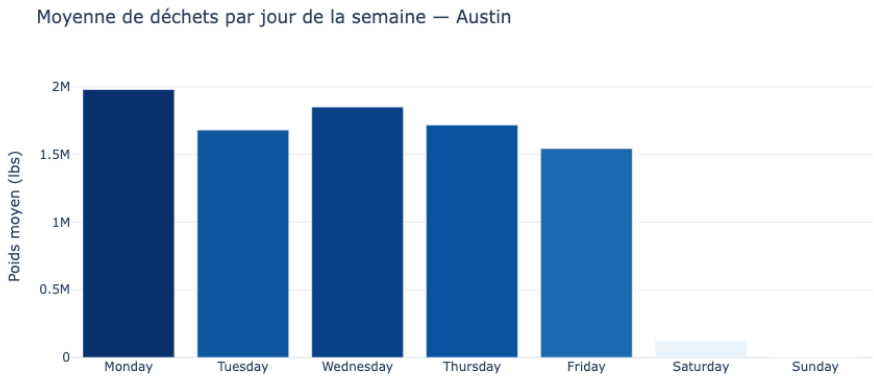

FIGURE 2 – Saisonnalité hebdomadaire : moyenne des déchets collectés par jour de la semaine. Les weekends présentent une collecte quasi nulle, ce qui justifie une modélisation différenciée par jour.

La figure 1 met en évidence une légère tendance haussière sur la période, cohérente avec la croissance démographique d'Austin (+40% sur la décennie). La figure 2 confirme la saisonnalité hebdomadaire décrite dans le papier original, avec un pic le lundi (rattrapage du weekend) et une activité quasi nulle le samedi et le dimanche.

2.3 Prétraitement

Le prétraitement suit les trois étapes du papier :

1. **Suppression des outliers** par méthode IQR, appliquée *séparément par jour de la semaine*. Cette adaptation est un apport par rapport au papier, qui ne précise pas sa méthode. Un IQR global traiterait les weekends comme des outliers alors qu'ils représentent un pattern normal.
2. **Imputation des valeurs manquantes** par interpolation linéaire (472 jours manquants après réindexation sur un calendrier continu).
3. **Split train/test** : 70% pour l'entraînement (2005–2015), 30% pour le test (2015–2019).

Note sur la MAPE. Les weekends présentant des valeurs de collecte quasi nulles, la MAPE (Mean Absolute Percentage Error) y est mathématiquement instable (division par une valeur proche de zéro). Par convention, toutes les MAPE reportées dans ce rapport sont calculées **sur les jours de semaine uniquement** (lundi–vendredi), ce qui permet une comparaison cohérente avec les résultats du papier.

3 Modèles

3.1 Modèles reproduits du papier

Parmi les neuf modèles évalués dans Mudannayake et al. [2022], nous reproduisons les trois plus performants sur le dataset Austin, en utilisant les hyperparamètres reportés dans le Tableau 4 de l'article :

— **Linear Regression** : modèle de régression linéaire multiple avec features de lag ($n_{\text{lags}} = 360$) ;
— **Random Forest** : forêt aléatoire avec $n_{\text{estimators}} = 100$, max_depth $= 10$, $n_{\text{lags}} = 360$;
— **Prophet** : modèle de décomposition de séries temporelles développé par Meta, avec prise en charge automatique de la saisonnalité.

Tous les modèles sont implémentés via la librairie `Darts` [Herzen et al., 2022], utilisée dans le papier original.

3.2 Foundation model : Chronos

Chronos [Ansari et al., 2024] est un foundation model de forecasting développé par Amazon (2024), pré-entraîné sur des milliers de séries temporelles hétérogènes. Nous l'évaluons selon deux stratégies :

— **Zero-shot** : prédiction directe sur l'ensemble du test set (1 644 jours) sans aucun entraînement sur nos données ;
— **Rolling forecast** : prédiction glissante sur des horizons courts ($h \in \{7, 14, 30\}$ jours), plus adaptée aux capacités du modèle qui recommande un horizon ≤ 64 jours.

3.3 Approche multi-model

Conformément à la section 5.A.2 du papier, nous entraînons sept modèles Linear Regression séparés, un par jour de la semaine, avec $n_{\text{lags}} = 48$. Chaque modèle se spécialise sur les patterns de son jour, ce qui permet de mieux capturer la saisonnalité hebdomadaire.

3.4 Chronos multi-model

En combinant les deux approches précédentes, nous entraînons un pipeline Chronos rolling ($h = 7$) distinct pour chaque jour de la semaine. L'hypothèse testée est qu'un gain additif de MAPE similaire à celui observé sur Linear Regression (8,60% → 8,17%) pourrait se reproduire sur Chronos.

4 Résultats

4.1 Comparaison avec le papier

Table 1 – Comparaison des MAPE obtenues avec celles du papier (single-model, dataset Austin).

Modèle	**RMSE**	**MAPE (%)**	**MAPE papier (%)**
Linear Regression	247 952	8,60	8,03
Prophet	293 886	11,03	10,51
Random Forest	402 473	10,20	9,00

Linear Regression et Prophet sont reproduits à moins de 0,6 point près, ce qui valide notre approche. L'écart résiduel s'explique par l'absence de grid search exhaustif, que le papier appliquait pour optimiser finement les hyperparamètres. Random Forest présente un écart plus modéré (1,20 point), reflétant la variabilité inhérente à ce modèle stochastique d'une exécution à l'autre.

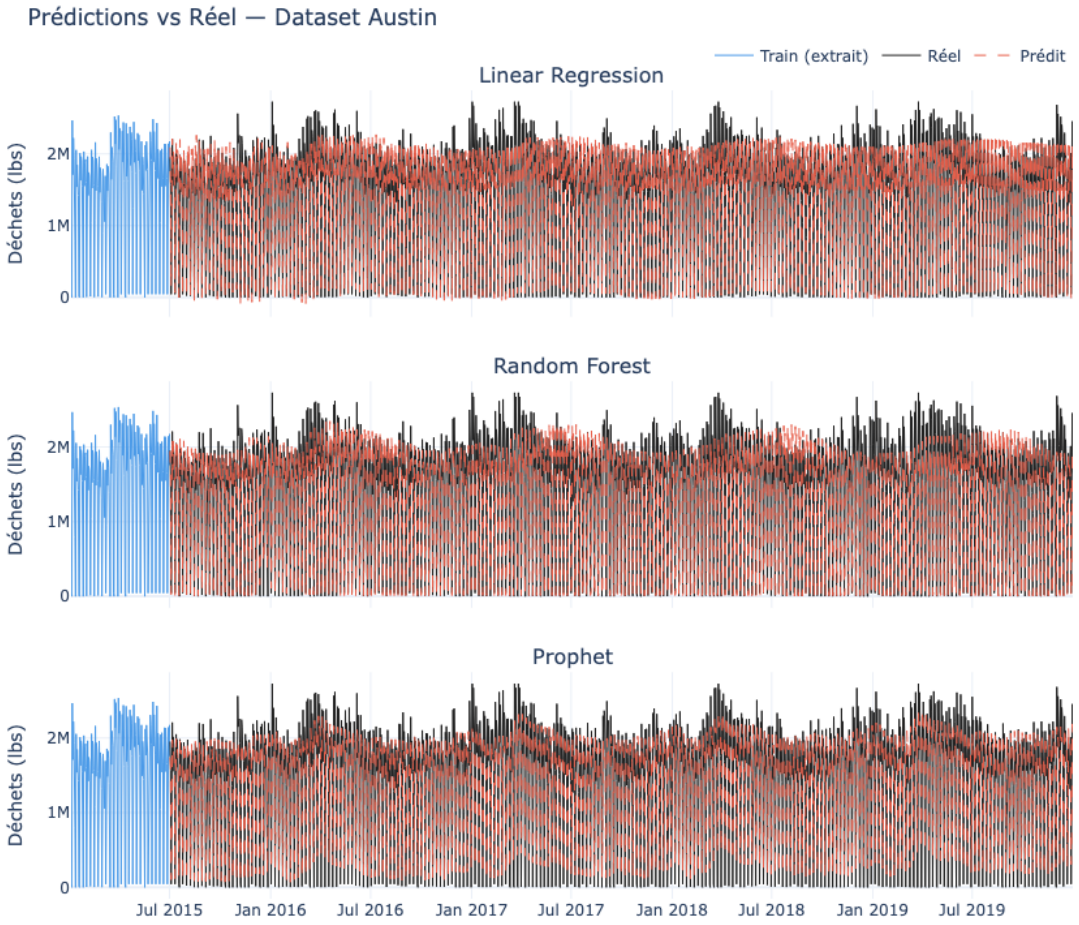

FIGURE 3 – Prédictions vs valeurs réelles sur le test set pour les trois modèles reproduits.

4.2 Chronos : impact de l'horizon

TABLE 2 – MAPE de Chronos selon la stratégie de prédiction.

Stratégie	**Horizon**	**MAPE (%)**
Zero-shot	1 644 jours	25,72
Rolling forecast	30 jours	8,44
Rolling forecast	14 jours	7,39
Rolling forecast	7 jours	**6,81**

L'horizon de prédiction est le facteur déterminant pour Chronos. En stratégie zero-shot sur 1 644 jours, la MAPE atteint 25,72%, soit le moins bon résultat de l'étude. En rolling forecast avec $h = 7$, Chronos devient le modèle le plus précis avec une MAPE de 6,81%, surpassant tous les modèles entraînés. Cette dégradation brutale au-delà des capacités recommandées du modèle (≤ 64 jours) illustre les limites des foundation models sur des horizons longs.

4.3 Approche multi-model

Table 3 – MAPE par jour de la semaine pour l'approche multi-model Linear Regression.

Jour	**MAPE (%)**
Lundi	8,18
Mardi	8,06
Mercredi	7,93
Jeudi	7,56
Vendredi	9,12
Global (lun–ven)	**8,17**
Single-model LR	8,60
Papier multi-model	8,03

L'approche multi-model (8,17%) reproduit quasi exactement le résultat du papier (8,03%), avec seulement 0,14 point d'écart. Le gain sur le single-model est modeste mais réel (8,60% → 8,17%), confirmant que la saisonnalité hebdomadaire est bien le facteur structurant de ces données.

4.4 Chronos multi-model

La combinaison rolling forecast Chronos + multi-model donne une MAPE de 7,08% et un RMSE de 179 646, contre 6,81% et 270 020 pour le rolling forecast global. L'hypothèse de gain additif ne se vérifie pas sur la MAPE : la spécialisation par jour améliore le RMSE (réduction de 33%) mais introduit un biais relatif légèrement plus élevé. Le rolling forecast global reste la meilleure approche sur la MAPE, probablement parce que Chronos bénéficie du contexte complet de la série pour capturer les transitions entre jours.

5 Empreinte carbone

5.1 Méthodologie

L'empreinte carbone de chaque modèle est mesurée avec CodeCarbon [Courty et al., 2023], qui estime les émissions de CO_2 équivalent à partir de la consommation électrique et du mix énergétique local. Pour les modèles nécessitant de nombreux appels (rolling forecast), la mesure est effectuée sur un sous-ensemble réduit puis extrapolée linéairement.

5.2 Résultats

TABLE 4 – Trade-off performance / empreinte carbone pour l'ensemble des modèles évalués.

Modèle	**CO_2 (g)**	**MAPE (%)**
Linear Regression	0,0002	8,60
Multi-model LR	0,0003	8,17
Prophet	0,0075	11,03
Random Forest	0,0386	10,20
Chronos zero-shot	0,0560	25,72
Chronos rolling $h = 7$	0,1737	**6,81**
Chronos multi-model $h = 7$	0,8044	7,08

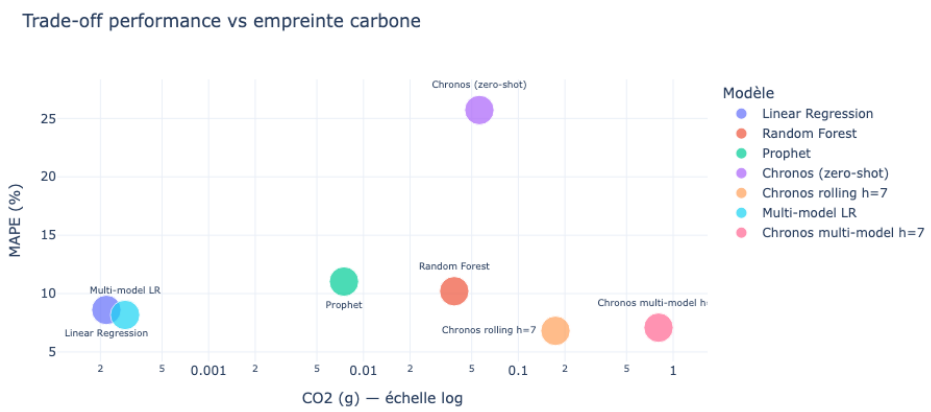

FIGURE 4 – Trade-off performance vs empreinte carbone. Le coin optimal (faible MAPE, faible CO_2) est occupé par Linear Regression et Multi-model LR.

Trois enseignements principaux se dégagent. Premièrement, **la complexité ne paye pas sur la MAPE** : Linear Regression et Multi-model LR sont simultanément les modèles les moins coûteux et les plus performants parmi les modèles entraînés. Deuxièmement, **Chronos rolling $h = 7$ est le seul foundation model compétitif** (6,81%), mais à un coût carbone environ 870 fois supérieur à Linear Regression. Troisièmement, **Chronos multi-model pousse la complexité trop loin** : à 0,8044 g CO_2eq, il est 5 fois plus coûteux que le rolling forecast global pour une MAPE légèrement moins bonne.

6 Discussion et critiques du papier

Cette étude met en évidence plusieurs limites du papier original.

Preprocessing opaque. Le papier ne précise pas la méthode de détection des outliers. Avec un IQR global, nous obtenions 1 112 outliers (22% des données), contre 29 mentionnés dans le papier. L'application de l'IQR par jour de la semaine ramène ce nombre à environ 65–80 outliers,

des résultats bien plus proches du papier et cohérents avec la réalité opérationnelle. Ce choix méthodologique non documenté est la principale source d'écarts de reproductibilité.

Absence de code public. Le papier ne met à disposition aucun code, rendant une reproduction exacte impossible indépendamment de la qualité des modèles.

Instabilité de la MAPE. Les auteurs ne mentionnent pas le problème d'instabilité de la MAPE sur les jours de weekend à collecte quasi nulle, ce qui constitue une lacune dans la description méthodologique.

Absence d'analyse environnementale. Le papier compare machine learning et deep learning uniquement sur la performance prédictive, sans tenir compte des coûts computationnels et environnementaux. Notre analyse montre que les modèles classiques dominent sur les deux dimensions simultanément pour ce type de données structurées.

7 Conclusion

Ce projet reproduit avec succès les résultats principaux de Mudannayake et al. [2022] sur le dataset Austin, avec des écarts inférieurs à 0,6 point de MAPE pour Linear Regression et Prophet. L'approche multi-model reproduit quasi exactement le résultat du papier (8,17% vs 8,03%).

Les extensions originales apportent deux conclusions fortes. D'abord, Chronos rolling $h = 7$ offre la meilleure MAPE absolue (6,81%) mais au prix d'un coût carbone 870 fois supérieur à Linear Regression. Ensuite, sur des données structurées avec une saisonnalité hebdomadaire forte, les modèles classiques bien préprocessés sont imbattables en termes de rapport performance/empreinte environnementale.

Ces résultats invitent à une réflexion plus large sur la justification du recours aux foundation models et aux architectures complexes dans des contextes où des modèles simples et interprétables suffisent.

Références

Abdul Fatir Ansari, Lorenzo Stella, Caner Turkmen, Xiyuan Zhang, Pedro Mercado, Huibin Shen, Oleksandr Shchur, Syama Sundar Rangapuram, Sebastian Pineda Arango, Shubham Kapoor, Jasper Zschiegner, Danielle C. Maddix, Hao Wang, Michael W. Mahoney, Kari Torkkola, Andrew Gordon Wilson, Michael Bohlke-Schneider, and Yuyang Wang. Chronos : Learning the language of time series. *Transactions on Machine Learning Research*, 2024.

City of Austin. Waste collection & diversion report (daily). https://data.austintexas.gov/Utilities-and-City-Services/Waste-Collection-Diversion-Report-daily-/mbnu-4wq9, 2024.

Victor Courty, Goyal-Kamal, Jonathan Montoya, Kadan Lottick, Siddharth Goyal, Douglas Sherwood, Ziyad Rattner, Nikola Milojevic-Dupont, Tegan Maharaj, and Alexandra Sasha Luccioni. Codecarbon : Estimate and track carbon emissions from machine learning computing. https://github.com/mlco2/codecarbon, 2023.

Julien Herzen, Francesco Lässig, Samuele Giuliano Piazzetta, Thomas Neuer, Léo Tafti, Guillaume Raille, Tomas Van Pottelbergh, Marek Pasieka, Andrzej Skrodzki, Nicolas Huguenin, Maxime Dumonal, Jan Kościsz, Dennis Bader, Frédéric Gusset, Mounir Benheddi, Camila Williamson, Michal Kosinski, Matej Petrik, and Gaël Grosch. Darts : User-friendly modern machine learning for time series. *Journal of Machine Learning Research*, 23(124) :1–6, 2022.

Oshan Mudannayake, Disni Rathnayake, Jerome Dinal Herath, Dinuni K. Fernando, and MGNAS Fernando. Exploring machine learning and deep learning approaches for multi-step forecasting in municipal solid waste generation. *IEEE Access*, 10 :122570–122585, 2022. doi : 10.1109/ACCESS.2022.3221941.